

Parte I

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 2

Modelado de la Incertidumbre en Sistemas de Diagnóstico Médico mediante Redes Bayesianas

Autor: Miguel Alejandro Armas Ordoñez (miguel.armas@unl.edu.ec)
Técnica de IA: Redes Bayesianas

2.1. Introducción

El diagnóstico médico constituye uno de los procesos cognitivos más complejos que enfrenta la medicina moderna. Esta complejidad no deriva únicamente de la diversidad de patologías o de la sofisticación de las pruebas clínicas disponibles, sino de una característica fundamental e irreducible: la incertidumbre. Dicha incertidumbre emerge de múltiples fuentes, entre ellas la variabilidad biológica entre pacientes, la imprecisión inherente a los instrumentos de medición, la incompletitud frecuente de los registros clínicos y las limitaciones de los modelos fisiopatológicos vigentes [1,2]. En este escenario, los sistemas de soporte a la toma de decisiones clínicas deben ser capaces de razonar de forma probabilística, actualizando sus estimaciones a medida que nueva evidencia es incorporada.

Los enfoques deterministas tradicionales, basados en árboles de decisión o sistemas de reglas fijas, presentan una fragilidad estructural ante datos ruidosos o ausentes: una variable faltante puede colapsar por completo el proceso de inferencia [3,4]. Frente a esta limitación, las redes bayesianas (RB) emergen como un paradigma alternativo de notable solidez teórica y práctica. Al codificar el conocimiento médico en una estructura gráfica probabilística, las RB permiten razonar de manera coherente incluso cuando la información disponible es parcial, combinando el juicio experto con la evidencia empírica bajo un marco matemático unificado y transparente [5,6].

El interés por las redes bayesianas en el ámbito médico no es reciente. Desde los trabajos pioneros de la década de 1990 [7,8], estas estructuras han demostrado su utilidad en dominios que van desde el diagnóstico de enfermedades crónicas hasta la triage en urgencias. Sin embargo, es en los últimos años cuando su aplicabilidad se ha expandido de forma notable, impulsada por la disponibilidad masiva de datos clínicos electrónicos, el desarrollo de algoritmos de aprendizaje automático más eficientes y la creciente demanda de sistemas de inteligencia artificial interpretables y auditables en el sector salud [1,9]. A diferencia de los modelos de «caja negra», las RB ofrecen una representación explícita de las dependencias causales entre variables, lo que facilita su validación por parte de los profesionales clínicos y su integración en los flujos de trabajo hospitalarios [10,11].

La pregunta central que articula el presente capítulo es: *¿Cómo se utilizan las redes baye-*

sianas para modelar la incertidumbre en sistemas de diagnóstico médico? Dar respuesta a esta pregunta exige examinar tanto los fundamentos matemáticos que sustentan el formalismo bayesiano como la evidencia empírica acumulada en la literatura especializada sobre su desempeño real en entornos clínicos. Este análisis es especialmente pertinente en el contexto de la ingeniería de sistemas inteligentes, donde la capacidad de gestionar la incertidumbre de forma explícita y justificable no es un lujo sino un requisito esencial para la adopción responsable de la inteligencia artificial en la práctica médica [12, 13].

El presente capítulo se organiza de la siguiente manera: la sección de **Fundamentos Teóricos** presenta la definición matemática formal de las redes bayesianas —incluyendo la propiedad de Markov, la factorización de la distribución conjunta y los algoritmos de inferencia exacta y aproximada— así como los métodos de aprendizaje de estructura y parámetros. La sección de **Metodología y Análisis de la Literatura** describe el procedimiento sistemático de búsqueda y selección bibliográfica seguido en este trabajo, expone un análisis comparativo del rendimiento de las RB en distintos dominios clínicos, resume los resultados cuantitativos más relevantes de la literatura mediante una tabla comparativa, e identifica las tendencias actuales y los vacíos de investigación detectados. Finalmente, la sección de **Conclusiones** sintetiza los hallazgos principales, discute las limitaciones del enfoque y propone líneas de trabajo futuro.

2.2. Fundamentos Teóricos

Las redes bayesianas representan un paradigma esencial en el campo de los modelos gráficos probabilísticos, combinando la teoría de grafos con el cálculo de probabilidades para gestionar la incertidumbre en dominios complejos como la medicina [1, 14]. A diferencia de los sistemas de reglas clásicos, que modelan el conocimiento de forma rígida y binaria, las RB expresan el conocimiento experto mediante distribuciones de probabilidad condicional, lo que les permite adaptarse de forma natural a la ambigüedad y variabilidad propias del razonamiento clínico [4, 5]. Formalmente, una RB se define como un par (G, θ) , donde G constituye la estructura cualitativa —que codifica las dependencias entre variables— y θ el componente cuantitativo —que cuantifica la intensidad de dichas dependencias [6, 14].

2.2.1. Definición Matemática

La estructura cualitativa $G = (V, E)$ es un grafo acíclico dirigido (DAG), donde los nodos V representan variables aleatorias del dominio médico —tales como síntomas, factores de riesgo, resultados de laboratorio o diagnósticos definitivos— y los arcos dirigidos E codifican las dependencias probabilísticas o relaciones de causalidad entre ellas [1, 4]. La semántica del DAG exige la ausencia de ciclos dirigidos, lo que garantiza que no existan trayectorias cerradas que retornen a un mismo nodo, permitiendo una interpretación causal coherente y evitando contradicciones lógicas en el proceso de inferencia [1, 2].

El núcleo de la potencia computacional de las RB reside en la propiedad de Markov, la cual establece que una variable X_i es condicionalmente independiente de sus no-descendientes dado el conjunto de sus padres $Pa(X_i)$ [2, 4]. Esta propiedad permite descomponer una distribución de probabilidad conjunta global en un producto de distribuciones de probabilidad locales, proceso conocido como factorización [6, 14]:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid Pa(X_i)) \quad (2.1)$$

Esta factorización reduce drásticamente la complejidad paramétrica del sistema. Por ejemplo, en un dominio con n variables binarias, una representación exhaustiva de la distribución conjunta requeriría especificar $2^n - 1$ parámetros; mediante una RB, solo es necesario definir las tablas de probabilidad condicional (CPT) para cada nodo basándose en sus padres inmediatos, lo

que supone una reducción exponencial del espacio de parámetros [1, 7]. En un escenario clínico de diagnóstico de diabetes, esto se traduce en que la probabilidad de la enfermedad depende directamente únicamente de factores clave —como el índice de masa corporal, el nivel glucémico en ayunas o los antecedentes familiares— y no de todas las combinaciones posibles de variables presentes en el sistema [15].

El componente cuantitativo θ del modelo está constituido precisamente por el conjunto de CPTs de cada nodo. Cada tabla $P(X_i \mid Pa(X_i))$ especifica la distribución de probabilidad de la variable X_i para cada combinación posible de estados de sus nodos padre. En el caso de variables discretas binarias, la tabla de un nodo con k padres contiene 2^k entradas, cada una de ellas una probabilidad condicionada [1, 14]. Esta representación local y modular facilita tanto la incorporación de conocimiento experto —mediante la especificación directa de las probabilidades por parte de un clínico especialista— como el aprendizaje automático a partir de registros históricos de pacientes [5, 16].

2.2.2. Inferencia y Aprendizaje

El proceso de razonamiento en una RB se denomina inferencia y consiste en el cálculo de probabilidades a posteriori de variables no observadas tras la presentación de nueva evidencia E [1, 17]. Este mecanismo se rige por el teorema de Bayes:

$$P(H \mid E) = \frac{P(E \mid H) P(H)}{P(E)} \quad (2.2)$$

donde H representa la hipótesis diagnóstica, $P(H)$ la probabilidad a priori de dicha hipótesis antes de observar la evidencia, $P(E \mid H)$ la verosimilitud de observar la evidencia dado que la hipótesis es cierta, y $P(E)$ el factor de normalización o evidencia marginal. En la práctica clínica, este mecanismo permite actualizar de forma continua la probabilidad de cada diagnóstico diferencial a medida que se incorporan nuevos resultados de laboratorio, hallazgos de imagen o síntomas adicionales [2, 18].

Dependiendo de la complejidad topológica del DAG, la inferencia puede ser de dos tipos:

1. **Exacta:** Se utiliza en redes con estructuras tratables, generalmente aquellas que poseen topologías de árbol o politree. El algoritmo de árbol de unión (JLO por sus siglas en inglés) es el estándar en este ámbito; este transforma el DAG original mediante procesos de «moralización» y «triangulación» para crear una estructura de árbol de unión que permite la propagación de mensajes y la actualización de creencias de forma eficiente, con una complejidad computacional exponencial en el ancho del árbol [10, 18].
2. **Aproximada:** Es necesaria cuando la estructura de la red es densa o multiconectada, situación en la que el cálculo exacto se torna NP-duro [19, 20]. Se emplean métodos de Monte Carlo basados en cadenas de Markov (MCMC), como el muestreo de Gibbs (*Gibbs sampling*), que genera muestras de la distribución conjunta para estimar las probabilidades requeridas mediante métodos estadísticos de aproximación [10, 21]. Otros enfoques incluyen el muestreo por importancia y la inferencia variacional, que aproxima la distribución posterior mediante una estructura más simple y manejable minimizando la divergencia de Kullback-Leibler respecto a la distribución real [19, 20].

Por otro lado, el aprendizaje de una RB a partir de datos empíricos se divide en dos fases críticas e interdependientes. El **aprendizaje de estructura** busca determinar la configuración óptima de arcos a partir de los datos, empleando tres enfoques principales:

- *Algoritmos basados en restricciones:* utilizan pruebas estadísticas de independencia condicional para determinar qué pares de variables deben o no estar conectados (por ejemplo, los algoritmos IC o IAMB) [1, 14].

- *Algoritmos basados en puntuación*: realizan búsquedas heurísticas sobre el espacio de DAGs —como *Hill-Climbing* o *Tabu Search*— para maximizar métricas de bondad de ajuste como el criterio BIC (*Bayesian Information Criterion*) o el score K2 [6, 10].
- *Enfoques híbridos*: como el algoritmo MMHC (*Max-Min Hill Climbing*), que combina una fase de restricciones para acotar el espacio de búsqueda con una fase de puntuación para la optimización final, mejorando tanto la escalabilidad como la precisión estructural [6, 14].

Finalmente, el **aprendizaje de parámetros** consiste en estimar las CPTs de los nodos una vez fijada la estructura. Se utiliza la Estimación de Máxima Verosimilitud (MLE) cuando se dispone de conjuntos de datos completos y suficientemente grandes [6, 14]. En cambio, cuando los datos son escasos o presentan valores ausentes —situación habitual en registros clínicos reales— se prefiere la estimación bayesiana con distribuciones *prior* conjugadas, como la distribución de Dirichlet, que permite integrar el conocimiento experto previo directamente en las CPTs y evita el sobreajuste (*overfitting*) en muestras pequeñas [4, 21]. Esta característica ha demostrado ser especialmente valiosa en el diagnóstico de patologías de baja prevalencia, como la artritis reumatoide en estadios tempranos, donde la combinación de guías clínicas codificadas y datos de pacientes ha superado el rendimiento de modelos puramente empíricos [5, 16].

2.2.3. Variantes Estructurales de las Redes Bayesianas

La flexibilidad del formalismo bayesiano ha dado lugar a diversas extensiones que amplían su expresividad para problemas médicos específicos. Entre las más relevantes en la literatura destacan las siguientes:

Las **Redes Bayesianas Dinámicas** (DBNs) extienden el modelo estático al dominio temporal, incorporando dependencias entre estados de una misma variable en instantes de tiempo consecutivos. Esta variante es especialmente adecuada para el modelado de la progresión de enfermedades crónicas o la evolución de un paciente en cuidados intensivos, donde el estado clínico en un instante determinado depende tanto de la evidencia actual como del historial previo [1, 4].

Las **Redes Bayesianas Causales** incorporan explícitamente el concepto de intervención causal, distinguiendo entre observaciones correlacionales e intervenciones directas sobre el sistema. Bajo el formalismo del operador *do*(·) de Pearl, estas redes permiten responder preguntas del tipo «¿qué ocurriría si se administrara este fármaco?», lo que las convierte en una herramienta de enorme valor para la evaluación de estrategias terapéuticas y el análisis contrafactual en medicina personalizada [10, 22].

Las **Redes Bayesianas Híbridas** (HBNs) combinan nodos con variables discretas y continuas en la misma estructura, utilizando distribuciones gaussianas condicionadas linealmente para las variables continuas. Esta capacidad es fundamental en dominios biomédicos, donde conviven variables categóricas —como diagnósticos o grupos sanguíneos— con variables numéricas continuas —como niveles hormonales, presión arterial o biomarcadores séricos [2, 17].

Finalmente, las **Redes Bayesianas con Capas Profundas** o enfoques de aprendizaje profundo bayesiano sustituyen las CPTs paramétricas por redes neuronales que aprenden representaciones complejas a partir de datos de alta dimensionalidad, como imágenes médicas o secuencias genómicas. El uso de técnicas como el *MC-Dropout* permite cuantificar la incertidumbre epistémica de las predicciones, lo que es esencial para la colaboración segura entre el modelo y el clínico [9, 20].

2.3. Metodología y Análisis de la Literatura

La revisión exhaustiva de la literatura seleccionada revela que las redes bayesianas son herramientas versátiles, aplicadas en dominios que van desde el diagnóstico de enfermedades crónicas hasta la medicina de urgencias [1, 23]. Ejemplos destacados incluyen el modelado de la artritis

reumatoide [16], el diagnóstico de lupus eritematoso sistémico [24], la identificación etiológica de condiciones inflamatorias en medicina interna [4, 19] y la detección de sepsis o infartos de miocardio en entornos críticos [23, 25].

La metodología predominante para evaluar estos sistemas incluye la validación cruzada de 10 pliegues y el análisis de métricas como el Área Bajo la Curva ROC (AUC), la sensibilidad y la especificidad [5, 20, 21]. La validación cruzada de 10 pliegues consiste en dividir el conjunto de datos en diez partes iguales, utilizando nueve para entrenamiento y una para prueba en cada iteración, rotando el proceso hasta que todas las particiones han actuado como conjunto de prueba. Esta estrategia garantiza una estimación robusta y con baja varianza del rendimiento real del modelo sobre datos no vistos [6]. El AUC es el parámetro preferido para cuantificar la capacidad discriminativa del modelo: un valor cercano a 1 indica un clasificador ideal, mientras que valores superiores a 0.75 se consideran aceptables en la práctica clínica [1]. La sensibilidad mide la proporción de casos positivos correctamente identificados —relevante cuando el costo de un falso negativo es alto, como en el cribado oncológico— mientras que la especificidad evalúa la precisión en los negativos —crítica cuando la confirmación de la ausencia de enfermedad es necesaria antes de un procedimiento invasivo— y ambas métricas se derivan directamente de la matriz de confusión [1, 24].

2.3.1. Procedimiento de Búsqueda y Selección de la Literatura

El presente trabajo se enmarca en un proyecto de aula de la asignatura Metodología de la Investigación en Computación [13], cuyo objetivo es rescatar las técnicas de inteligencia artificial anteriores a la IA generativa —muchas de las cuales forman la base teórica de los sistemas inteligentes actuales— y visibilizar el conocimiento que abordan los ingenieros que construyen estas herramientas [12]. A cada uno de los 43 estudiantes se le asignó una pregunta de investigación vinculada a una técnica de IA; en este caso, la pregunta sobre redes bayesianas en diagnóstico médico.

El proceso de revisión se desarrolló en cuatro fases progresivas, asegurando la trazabilidad y la reproducibilidad de la búsqueda. Inicialmente, cada estudiante descompuso su pregunta en palabras clave y las articuló mediante operadores lógicos booleanos (AND, OR, NOT) para definir cadenas de búsqueda estructuradas. Estas cadenas se ejecutaron en las bases de datos IEEE Xplore y ACM Digital Library, obteniendo como primer entregable una matriz con cinco artículos científicos pertinentes. Desde esta etapa se incorporó el uso de gestores bibliográficos (Mendeley y Zotero), la escritura en $\text{\LaTeX}$ con Overleaf y la herramienta NotebookLM para extraer información no sesgada y volcarla en una matriz de extracción de datos.

En una segunda fase se ampliaron las bases de datos consultadas a ScienceDirect, Springer y Lens, con el fin de localizar 15 artículos adicionales dentro del mismo contexto temático, alcanzando un total de 20 referencias en los gestores bibliográficos. En esta etapa, los estudiantes aplicaron un método de jerarquización mediante NotebookLM, que permitió identificar los artículos de mayor utilidad para responder a la pregunta de investigación mediante análisis semántico automatizado.

La tercera fase consistió en la búsqueda en Scopus, utilizando la cadena original o una versión enriquecida con descriptores MeSH, para extraer los metadatos de los artículos relacionados. Estos metadatos se exportaron en formato BibTeX y archivo de texto, lo que facilitó su integración tanto en la jerarquización con NotebookLM como en la gestión con Mendeley y en la compilación con Overleaf de los artículos que finalmente sustentan la respuesta a la pregunta de investigación. Adicionalmente, se empleó Scopus AI para generar un informe breve sobre cada pregunta, exportado en PDF como insumo complementario.

Todo el flujo de trabajo —desde la definición de cadenas de búsqueda hasta la redacción final en Overleaf— siguió principios de revisión sistemática para minimizar sesgos, aprovechando fuentes de alto impacto como IEEE Xplore, ACM, ScienceDirect, Springer y Scopus, habituales en estudios similares sobre inteligencia artificial aplicada a la salud [5]. La combinación de herra-

mientas actuales de gestión y análisis garantizó una síntesis objetiva de la literatura, centrada en los fundamentos de las RB como técnica clásica de la IA con vigencia demostrada en entornos clínicos contemporáneos.

2.3.2. Análisis Comparativo por Dominio Clínico

En el ámbito de las enfermedades crónicas, se destaca el uso de RB para el diagnóstico de la artritis reumatoide, donde modelos basados en conocimiento experto —construidos a partir de guías clínicas y criterios de clasificación de la EULAR— alcanzan un AUC de 0.86, superando consistentemente a modelos puramente orientados por datos [5, 16]. Este resultado subraya la importancia de incorporar el conocimiento clínico estructurado en el diseño de la red, especialmente cuando el conjunto de datos disponible es limitado o presenta desbalance entre clases. En dermatología, la integración de redes neuronales profundas con capas bayesianas (*Bayesian DenseNet-169*) ha permitido cuantificar la incertidumbre de las predicciones en lesiones cutáneas, logrando precisiones de clasificación del 90 % mediante un flujo de trabajo híbrido que deriva los casos inciertos a la revisión de expertos humanos, reduciendo así la tasa de errores diagnósticos críticos [20, 26].

En el dominio de la neurología, las RB han demostrado una capacidad singular para modelar la fase prodrómica de enfermedades neurodegenerativas complejas como el Parkinson. Mediante el uso de técnicas de *bootstrapping* para estimar la confianza probabilística de las conexiones estructurales, se han logrado cuantificar las interdependencias entre marcadores genéticos —como las variantes del gen LRRK2—, indicadores de estilo de vida —como el tabaquismo y la actividad física— y marcadores neurológicos —como la hiperecogenicidad de la sustancia negra—, permitiendo la generación de cohortes sintéticas realistas para investigación clínica sin comprometer la privacidad de los pacientes [27]. Asimismo, en el diagnóstico de demencia y enfermedad de Alzheimer, el uso de modelos híbridos que combinan conocimiento experto con datos ha reportado valores de AUC situados entre 0.86 y 0.97, demostrando ser herramientas altamente competitivas frente a clasificadores puramente empíricos y permitiendo una identificación más precisa de los diferentes estadios de la enfermedad [1].

La oncología representa otro campo de aplicación crítica donde la gestión de la incertidumbre es vital. En el diagnóstico y pronóstico de supervivencia del cáncer de pulmón, el empleo de algoritmos de descubrimiento causal híbridos como CaMML ha permitido obtener estructuras de red que superan significativamente a los modelos construidos únicamente a partir del juicio clínico manual (AUC 0.81 frente a 0.75), capturando dependencias estadísticas implícitas en grandes bases de datos nacionales [10]. Para el cáncer de mama, sistemas como MammoNet integran de forma natural hallazgos radiológicos —incluyendo características morfológicas y de densidad tisular extraídas por radiólogos expertos— con antecedentes del paciente como la edad, los antecedentes familiares y los resultados de biopsias previas, alcanzando precisiones superiores al 93 % y ofreciendo una representación de las anomalías mamarias mucho más intuitiva y explicable que los índices de riesgo convencionales [1, 8].

Las aplicaciones en medicina cardiovascular subrayan la superioridad técnica de las RB sobre modelos estadísticos clásicos para capturar relaciones no lineales entre factores de riesgo. En pacientes con miocardiopatía dilatada, un modelo basado en el algoritmo *Tabu search* predijo la incidencia de ictus isquémico con un AUC de 0.822 en el conjunto de prueba, superando a la regresión logística tradicional (AUC 0.769) gracias a su flexibilidad para modelar interacciones entre factores como la hipertensión, la hiperlipidemia, la fibrilación auricular y la disfunción renal [22]. De igual forma, en casos de endocarditis infecciosa, las RB han sido fundamentales para identificar la interacción entre factores como el tamaño de la vegetación valvular y la infección por *S. aureus* en la predicción de complicaciones embólicas, permitiendo una estratificación del riesgo más precisa que los modelos de puntuación convencionales [28].

En cuanto al manejo de datos faltantes —una restricción omnipresente en los registros clínicos reales—, las RB han demostrado una robustez superior a la de los modelos de regresión logística,

los cuales requieren registros completos para operar correctamente [2, 29]. Por ejemplo, en el diagnóstico de tuberculosis pulmonar en ausencia de un «estándar de oro» perfecto, el análisis de clases latentes bayesianas permitió estimar la prevalencia real de la enfermedad en una cohorte comunitaria con valores plausibles de 1.1 %, resolviendo la dependencia condicional residual entre las pruebas diagnósticas y evitando las estimaciones sesgadas (18.6 %) que producía el modelo de independencia condicional estándar [21].

Finalmente, en enfermedades infecciosas y medicina de urgencias, la versatilidad de las RB permite la hibridación con arquitecturas de aprendizaje profundo para maximizar la precisión sin sacrificar la transparencia diagnóstica. El sistema *MulNet* para la detección de neumonía adquirida en la comunidad fusiona imágenes de rayos X con reportes clínicos en lenguaje natural para alcanzar una sensibilidad del 0.94, proporcionando además explicaciones diagnósticas trazables mediante la inspección directa de las tablas de probabilidad condicional de la red bayesiana subyacente [6]. En el diagnóstico del dengue en entornos de recursos limitados, las RB han demostrado una capacidad discriminativa (AUC 0.80) comparable a la de médicos especialistas en enfermedades infecciosas, con la ventaja adicional de su consistencia y disponibilidad continua [30]. A diferencia de los modelos de «caja negra» o los árboles de decisión, que pueden colapsar ante la ausencia de datos en variables críticas, las RB permiten realizar intervenciones causales y responder a preguntas hipotéticas (*what-if*), facilitando el soporte de decisiones en condiciones de laboratorio limitadas [10, 11, 23].

2.3.3. Resultados Cuantitativos de Rendimiento

La Tabla 2.1 resume los parámetros de rendimiento extraídos directamente de los estudios analizados, subrayando las ventajas tecnológicas y las restricciones detectadas en cada caso.

La síntesis de los resultados cuantitativos confirma un patrón consistente en la literatura: las redes bayesianas alcanzan o superan el umbral de AUC de 0.75 considerado clínicamente aceptable en la amplia mayoría de los dominios evaluados, con valores medios situados en torno a 0.82 [1]. Resulta especialmente notable que, en los casos donde se comparó directamente con la regresión logística, las RB mostraron ventajas estadísticamente significativas, atribuibles a su mayor capacidad para modelar relaciones no lineales y para operar con conjuntos de datos con valores ausentes [2, 22]. Asimismo, el tiempo de inferencia inferior a 100 ms reportado para implementaciones en GPU [20] sugiere que las restricciones computacionales que históricamente limitaban la adopción clínica están siendo superadas gracias al hardware contemporáneo.

2.3.4. Tendencias y Vacíos en la Literatura

Se observa una clara y acelerada tendencia hacia la hibridación de las RB con técnicas de aprendizaje profundo (*Deep Learning*) con el objetivo de mejorar la explicabilidad de los modelos de «caja negra» sin sacrificar la precisión que estos ofrecen [9, 11, 26]. Esta integración se ha extendido recientemente hacia el procesamiento de datos multimodales, donde las RB actúan como el motor de fusión para combinar imágenes médicas de alta resolución, reportes clínicos en lenguaje natural y metadatos estructurados del paciente [6, 26]. La incorporación de información clínica contextual —como la edad, el sexo y la localización anatómica de la lesión— en modelos de diagnóstico dermatológico ha generado una mejora documentada del 19.3 % en la precisión balanceada (BACC) respecto a modelos que únicamente procesan imágenes, lo que evidencia el valor añadido de la fusión multimodal mediada por RB [26].

Otra tendencia relevante es la combinación de RB con lógica difusa para manejar la ambigüedad lingüística inherente al juicio experto, transformando descriptores cualitativos como «levemente elevado» o «moderadamente positivo» en intervalos de probabilidad cuantificados que pueden ser directamente incorporados a las CPTs [11, 17]. Para habilitar sistemas a gran escala en dominios de medicina interna con cientos de variables interrelacionadas, la literatura destaca el empleo de técnicas de inferencia aproximada —como los métodos variacionales y el

muestreo de Monte Carlo con *dropout* (*MC-Dropout*)— que permiten obtener estimaciones de incertidumbre robustas sin incurrir en costos computacionales prohibitivos [19, 20].

Sin embargo, persiste una controversia no resuelta en la literatura respecto a la estrategia óptima de construcción de las redes: mientras algunos investigadores abogan por modelos puramente automáticos basados en datos, argumentando mayor objetividad y escalabilidad [14, 29], otros demuestran empíricamente que la incorporación manual de conocimiento experto es condición necesaria para garantizar la validez clínica y la coherencia causal del modelo [5, 33]. Esta controversia se vincula estrechamente con el problema de la calidad de los datos: las estructuras aprendidas automáticamente de registros hospitalarios suelen reflejar sesgos estadísticos y correlaciones artefactuales —como la correlación entre la prescripción de un fármaco y la mejoría del paciente sin incluir el diagnóstico subyacente— que no siempre coinciden con los mecanismos causales fisiopatológicos reales [5, 10].

A pesar de los avances documentados, persisten vacíos críticos que limitan la generalizabilidad y la adopción clínica masiva de estas herramientas. El vacío más recurrente es la escasez de validación externa: revisiones sistemáticas indican que solo el 5 % de los estudios publican evaluaciones de sus modelos en poblaciones distintas a las de entrenamiento [5], lo que impide determinar si el rendimiento reportado es transferible a otros hospitales, regiones geográficas o grupos etarios. Esta limitación es especialmente grave en modelos para la predicción de eventos cardiovasculares o neurodegenerativos, cuya validez depende fuertemente de las características demográficas de la cohorte original [27, 28].

Se detecta también una alarmante falta de estandarización en el reporte de modelos gráficos probabilísticos en publicaciones biomédicas; aproximadamente el 48 % de los estudios identificados en revisiones sistemáticas omiten detalles metodológicos clave del proceso de desarrollo —como el algoritmo de aprendizaje de estructura empleado, el método de tratamiento de datos faltantes o los criterios de validación cruzada utilizados— lo que hace imposible la reproducción independiente de los resultados [5]. Un vacío adicional, quizás el más determinante para el impacto real de la tecnología, es la ausencia casi total de ensayos clínicos controlados que comparen prospectivamente el impacto en los resultados de los pacientes cuando el clínico es asistido por una RB frente a la práctica habitual sin asistencia computacional [5, 10].

Para cerrar la brecha entre la precisión demostrada en entornos de investigación y la utilidad práctica en el flujo de trabajo médico real, la literatura futura debe priorizar la creación de interfaces de usuario explicables e interactivas que permitan al clínico formular consultas dinámicas de tipo *what-if* sobre cualquier nodo de la red [1, 34]. Este enfoque transformaría a las RB de meros clasificadores estadísticos en verdaderos sistemas de soporte a la toma de decisiones clínicas, en los que el clínico puede explorar escenarios alternativos, comprender el peso de cada evidencia y justificar sus decisiones ante pacientes y comités de ética [4, 11].

2.4. Conclusiones

La revisión bibliográfica realizada confirma que las redes bayesianas constituyen una herramienta fundamental y madura para el modelado de la incertidumbre en medicina, respondiendo a la pregunta de investigación mediante su capacidad única de combinar probabilidades condicionales con estructuras causales explícitas y semánticamente interpretables [1, 6, 33]. Esta idoneidad técnica radica en la facultad de las RB para fusionar el conocimiento previo de expertos clínicos y la evidencia de la literatura científica con datos empíricos de pacientes reales, permitiendo construir modelos clínicamente coherentes incluso en escenarios donde la disponibilidad de datos es limitada, los registros son incompletos o la prevalencia de la enfermedad es baja [5, 16]. A diferencia de enfoques puramente estadísticos como la regresión logística —que exige independencia entre variables y registros completos— o las redes neuronales convencionales —cuyo razonamiento interno permanece opaco—, las RB capturan las interdependencias reales de los procesos fisiopatológicos y ofrecen una explicabilidad estructural que facilita la validación

clínica y la adopción responsable de la tecnología [6, 22].

Los principales hallazgos de esta revisión indican que:

- Las RB permiten una cuantificación precisa de la incertidumbre epistémica, facilitando la colaboración segura entre el sistema automático y el clínico mediante la derivación de casos con alta incertidumbre a la revisión especializada [20].
- La integración de conocimiento experto codificado en guías clínicas mitiga eficazmente las limitaciones impuestas por conjuntos de datos pequeños o incompletos, permitiendo el modelado efectivo de enfermedades raras, estadios prodrómicos complejos o patologías con alta variabilidad interindividual [5, 21, 27].
- El rendimiento predictivo agregado (AUC promedio superior a 0.75) es comparable o superior al de otros métodos de inteligencia artificial evaluados en los mismos contextos, con la ventaja diferencial de la interpretabilidad inherente a la estructura gráfica causal [1, 9].
- Las RB ofrecen una transparencia diagnóstica superior frente a los modelos de «caja negra», permitiendo a los clínicos visualizar en tiempo real cómo se actualizan las probabilidades a posteriori de cada diagnóstico diferencial al incorporar nueva evidencia [10, 11].
- Presentan una robustez excepcional frente a datos faltantes —una restricción omnipresente en la práctica clínica cotidiana que inhabilita a muchos otros clasificadores— gracias a su capacidad de inferencia marginal sobre los nodos con información disponible [10, 22].
- Poseen una flexibilidad única para actualizarse dinámicamente mediante el reentrenamiento incremental con nuevos diagnósticos confirmados, permitiendo que el modelo se adapte a la evolución temporal de los patrones epidemiológicos y mantenga su precisión a lo largo del tiempo [1, 33].

Como limitaciones relevantes, se identifican la alta complejidad computacional en modelos a gran escala —especialmente en procesos de inferencia exacta sobre redes densas—, la dependencia crítica de la calidad y representatividad de los datos de entrenamiento y la dificultad inherente a la elicitación del conocimiento experto, que consume tiempo y puede introducir sesgos subjetivos si no se apoya en metodologías estandarizadas [2, 5, 19]. Se observa además una marcada escasez de validaciones clínicas prospectivas y una falta generalizada de estándares uniformes para el reporte de modelos gráficos en salud, lo que dificulta la comparación sistemática entre estudios y la replicación independiente de los resultados [1, 5].

Las líneas de trabajo futuro deben enfocarse en el desarrollo de algoritmos de inferencia más eficientes para dispositivos móviles y sistemas embebidos, con vistas a democratizar el acceso a herramientas de soporte diagnóstico en entornos con recursos limitados [1, 35]. Es prioritario avanzar en la estandarización de marcos de trabajo (*frameworks*) que faciliten la adopción de estos sistemas en la práctica clínica diaria, incluyendo su integración con los estándares de historia clínica electrónica (HL7/FHIR) y la creación de interfaces visuales explicables que permitan al clínico formular consultas dinámicas de tipo *what-if* [1, 5, 34]. Finalmente, se recomienda con urgencia la realización de ensayos clínicos controlados que midan el impacto real de las RB en la calidad de las decisiones clínicas y en los resultados de salud de los pacientes, así como la exploración sistemática de modelos multimodales que integren datos genómicos de secuenciación masiva con señales fisiológicas provenientes de dispositivos *wearables* [5, 26, 35].

Tabla 2.1: Comparativa de rendimiento y características de los modelos de RB en la literatura.

Parámetro	Estudio	Valor	Ventaja tecnológica	Restricción
AUC (Artritis Reumatoide)	[5]	0.86	Integración efectiva de guías clínicas y juicio experto.	Sensible a la calidad de la extracción de conocimiento.
Precisión diagnóstica (Lesiones de piel)	[20]	90 %	Estimación de incertidumbre mediante <i>MC-Dropout</i> .	Requiere múltiples pasadas de inferencia (costo computacional).
Sensibilidad (Neumonía)	[6]	0.94	Uso de datos multi-fuente (imágenes y reportes clínicos).	Estructuras complejas pueden ser difíciles de interpretar visualmente.
Efectividad (Uveítis)	[31]	83 %	Capacidad de predecir etiologías basadas en perfiles individuales.	Limitado por el tamaño de muestra en etiologías raras.
AUC (Cáncer de pulmón)	[10]	0.81	Supera a los modelos basados únicamente en opinión clínica.	Sesgo potencial por datos retrospectivos de una sola base.
Precisión (Fallas en válvulas)	[17]	Intervalos ^a	Uso de lógica difusa para manejar variables inciertas.	Complejidad en la formalización de reglas difusas.
Robustez ante datos faltantes	[21]	Alta	Plausibilidad en estimaciones sin estándar de referencia.	Alta carga computacional en el muestreo de Gibbs (MCMC).
Tiempo de inferencia	[20]	<100 ms	Implementación eficiente en GPU para flujos híbridos.	Escalabilidad comprometida en redes con miles de nodos.
Interpretabilidad	[11]	Alta	Nodos representan conceptos clínicos de alto nivel (síntomas).	Difícil de automatizar para todas las patologías.
Manejo de muestras pequeñas	[32]	Adecuado	El modelado bayesiano evita el sobreajuste (<i>overfitting</i>).	Sensible a la elección de las distribuciones <i>prior</i> .
AUC (Ictus isquémico / DCM)	[22]	0.822	Captura interacciones no lineales entre factores de riesgo.	Requiere datos de entrenamiento balanceados por clase.
AUC (Diagnóstico dengue)	[30]	0.80	Comparable al rendimiento de especialistas en infecciosas.	Dependencia de la calidad del historial clínico del paciente.

^a El estudio reporta los resultados mediante intervalos de confianza; se recomienda incluir el rango concreto (p. ej., 0.85–0.95) para mayor precisión comparativa.

Referencias

- [1] K. Polotskaya, C. S. Muñoz-Valencia, A. Rabasa, J. A. Quesada-Rico, D. Orozco-Beltrán, and X. Barber, “Bayesian networks for the diagnosis and prognosis of diseases: A scoping review,” *Machine Learning and Knowledge Extraction*, vol. 6, pp. 1243–1262, 6 2024. [Online]. Available: <https://www.mdpi.com/2504-4990/6/2/58/htmlhttps://www.mdpi.com/2504-4990/6/2/58>
- [2] P. P. Rodrigues, D. F. Santos, and L. Leite, “Obstructive sleep apnea diagnosis: The bayesian network model revisited,” in *2015 IEEE 28th International Symposium on Computer-Based Medical Systems*, 6 2015, pp. 115–120.
- [3] A. T. S. AlObaidi and N. T. Mahmood, “Modified full bayesian networks classifiers for medical diagnosis,” in *2013 International Conference on Advanced Computer Science Applications and Technologies*, 12 2013, pp. 5–12.
- [4] P. J. Lucas, L. C. Gaag, and A. Abu-Hanna, “Bayesian networks in biomedicine and health-care,” *Artificial Intelligence in Medicine*, vol. 30, pp. 201–214, 5 2004.
- [5] E. Kyrimi, S. McLachlan, K. Dube, M. Neves, A. Fahmi, and N. Fenton, “A comprehensive scoping review of bayesian networks in healthcare: Past, present and future,” 5 2020.
- [6] H. Ren, A. B. Wong, W. Lian, W. Cheng, Y. Zhang, J. He, Q. Liu, J. Yang, C. J. Zhang, K. Wu, and H. Zhang, “Interpretable pneumonia detection by combining deep learning and explainable models with multisource data,” *IEEE Access*, vol. 9, pp. 95 872 – 95 883, 2021, cited by: 40; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85110657408?origin=resultslist>
- [7] C.-Y. Lee, M. Evens, L. Carmony, D. A. Trace, and F. Naeymi-Rad, “Recommending tests in a multimembership bayesian diagnostic expert system,” in *[1991] Computer-Based Medical Systems@proceedingsoftheFourthAnnualIEEESymposium*, 51991, pp.28 – –35.
- [8] C. E. Kahn, L. M. Roberts, K. A. Shaffer, and P. Haddawy, “Construction of a bayesian network for mammographic diagnosis of breast cancer,” *Computers in Biology and Medicine*, vol. 27, pp. 19–29, 1 1997. [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/9055043/>
- [9] G. Zhao, Q. Feng, C. Chen, Z. Zhou, and Y. Yu, “Diagnose like a radiologist: Hybrid neuro-probabilistic reasoning for attribute-based medical image diagnosis,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 44, pp. 7400–7416, 11 2022.
- [10] M. B. Sesen, A. E. Nicholson, R. Banares-Alcantara, T. Kadir, and M. Brady, “Bayesian networks for clinical decision support in lung cancer care,” *PLoS ONE*, vol. 8, p. 82349, 2013. [Online]. Available: www.plosone.org
- [11] V. Zarikas and S. V. Georgakopoulos, “Interpretable medical image diagnosis methodology using convolutional neural networks and bayesian networks,” in *2024 9th International Conference on Mathematics and Computers in Sciences and Industry (MCSI)*, 8 2024, pp. 128–133.

- [12] M. A. Armas Ordoñez, “Modelado probabilístico estructurado en la informática médica e ingeniería clínica,” *IEEE Transactions on Artificial Intelligence*, vol. 6, no. 2, pp. 112–125, 2025.
- [13] L. Chamba-Eras, *Metodología de la Investigación en Computación: Una Guía para el Diseño de Sistemas Inteligentes*. Loja, Ecuador: Editorial Universidad Nacional de Loja, 2026.
- [14] M. Scutari, “Learning bayesian networks with the bnlearn r package,” *Journal of Statistical Software*, vol. 35, pp. 1–22, 2010. [Online]. Available: <https://www.jstatsoft.org/index.php/jss/article/view/v035i03>
- [15] I. Lixandru-Petre, “Modeling a bayesian network for a diabetes case study,” 5 2020, pp. 1–4.
- [16] A. Fahmi, A. MacBrayne, E. Kyrimi, S. McLachlan, F. Humby, W. Marsh, and C. Pitzalis, “Causal bayesian networks for medical diagnosis: A case study in rheumatoid arthritis,” in *2020 IEEE International Conference on Healthcare Informatics (ICHI)*, 11 2020, pp. 1–7.
- [17] J. C. R. V. and A. S. Piqueras, “Learning bayesian networks for systems diagnosis,” in *Electronics, Robotics and Automotive Mechanics Conference (CERMA’06)*, vol. 2, 9 2006, pp. 125–130.
- [18] A. Djebbar and H. F. Merouani, “Mocabban : a modeling case base by a bayesian network applied to the diagnosis of hepatic pathologies,” in *International Conference on Computational Intelligence for Modelling, Control and Automation and International Conference on Intelligent Agents, Web Technologies and Internet Commerce (CIMCA-IAWTIC’06)*, vol. 2, 11 2005, pp. 678–685.
- [19] W. Wiegerinck, H. J. Kappen, E. T. Braak, W. T. Burg, M. J. Nijman, Y. L. O, and J. P. Neijt, “Approximate inference for medical diagnosis,” *Pattern Recognition Letters*, vol. 20, pp. 1231 – 1239, 1999, cited by: 24; All Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/0033220806?origin=resultslist>
- [20] A. Mobiny, A. Singh, and H. V. Nguyen, “Risk-aware machine learning classifier for skin lesion diagnosis,” *Journal of Clinical Medicine*, vol. 8, 2019, cited by: 88; All Open Access; Gold Open Access; Green Open Access. [Online]. Available: <https://www.scopus.com/pages/publications/85079980134?origin=resultslist>
- [21] A. Kipyegon, K. Id, L. Lynen, A. V. Heerden, E. Wong, K. Reither, E. Goetghebeur, and B. K. M. Jacobs, “Evaluation of tuberculosis diagnostic test accuracy using bayesian latent class analysis in the presence of conditional dependence between the diagnostic tests used in a community-based tuberculosis screening study,” 2023. [Online]. Available: <https://doi.org/10.1371/journal.pone.0282417>
- [22] Z.-X. Fan, C.-B. Wang, L.-B. Fang, L. Ma, T.-T. Niu, Z.-Y. Wang, J.-F. Lu, B.-Y. Yuan, and G.-Z. Liu, “Risk factors and a bayesian network model to predict ischemic stroke in patients with dilated cardiomyopathy,” *Frontiers in Neuroscience*, vol. Volume 16 - 2022, 2022. [Online]. Available: <https://www.frontiersin.org/journals/neuroscience/articles/10.3389/fnins.2022.1043922>
- [23] E. Gultepe, H. Nguyen, T. Albertson, and I. Tagkopoulos, “A bayesian network for early diagnosis of sepsis patients: a basis for a clinical decision support system,” in *2012 IEEE 2nd International Conference on Computational Advances in Bio and medical Sciences (IC-CABS)*, 2 2012, pp. 1–5.

- [24] Q. Xu, X. Wu, X. Chen, Z. Zhang, J. Wang, Z. Li, X. Chen, X. Lei, Z. Li, M. Ma, C. Chen, and L. Wu, "Diagnosis and activity prediction of sle based on serum raman spectroscopy combined with a two-branch bayesian network," *Frontiers in Immunology*, vol. Volume 16 - 2025, 2025. [Online]. Available: <https://www.frontiersin.org/journals/immunology/articles/10.3389/fimmu.2025.1467027>
- [25] C. yi Lin, J. xun Yin, X. Gao, J. yu Chen, and P. Qin, "A semantic modeling approach for medical image semantic retrieval using hybrid bayesian networks," in *Sixth International Conference on Intelligent Systems Design and Applications*, vol. 2, 10 2006, pp. 482–487.
- [26] Y. He, J. Liu, Y. Li, H. Zhou, L. Cai, and T. Cui, "Multimodal bayesian networks for automatic skin disease diagnosis," in *2024 IEEE International Conference on Bioinformatics and Biomedicine (BIBM)*, 12 2024, pp. 2018–2025.
- [27] M. Sood, U. Suenkel, A. K. von Thaler, H. U. Zacharias, K. Brockmann, G. W. Eschweiler, W. Maetzler, D. Berg, H. Fröhlich, and S. Heinzl, "Bayesian network modeling of risk and prodromal markers of parkinson's disease," *PloS one*, vol. 18, 2 2023. [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/36827273/>
- [28] B. Yuan, C. Wang, Z. Fan, C. Liu, L. Fang, L. Ma, W. Zou, G. Yuan, and G. Liu, "A bayesian network-based approach for identifying risk factors and predicting ischemic stroke in infective endocarditis patients," *Frontiers in Cardiovascular Medicine*, vol. Volume 10 - 2023, 2024. [Online]. Available: <https://www.frontiersin.org/journals/cardiovascular-medicine/articles/10.3389/fcvm.2023.1294229>
- [29] F. Liu and Q. Zhu, "Max-relevance and min-redundancy greedy bayesian network learning on high dimensional data," in *Third International Conference on Natural Computation (ICNC 2007)*, vol. 1, 8 2007, pp. 217–221.
- [30] C. Sa-ngamuang, P. Haddawy, V. Luvira, W. Piyaphanee, S. Iamsirithaworn, and S. Lawpoolsri, "Accuracy of dengue clinical diagnosis with and without ns1 antigen rapid test: Comparison between human and bayesian network model decision," *PLOS Neglected Tropical Diseases*, vol. 12, no. 6, pp. 1–14, 06 2018. [Online]. Available: <https://doi.org/10.1371/journal.pntd.0006573>
- [31] M. Athanasiou and J. Y. Clark, "A bayesian network model for the diagnosis of the caring procedure for wheelchair users with spinal injury," in *Twentieth IEEE International Symposium on Computer-Based Medical Systems (CBMS'07)*, 6 2007, pp. 433–438.
- [32] Z. S. Estabragh, M. M. R. Kashani, F. J. Moghaddam, S. Sari, and K. S. Oskooyee, "Bayesian network model for diagnosis of social anxiety disorder," in *2011 IEEE International Conference on Bioinformatics and Biomedicine Workshops (BIBMW)*, 11 2011, pp. 639–640.
- [33] O. Arsene, I. Dumitrache, and I. Mihiu, "Expert system for medicine diagnosis using software agents," *Expert Systems with Applications*, vol. 42, no. 4, pp. 1825–1834, 2015. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417414006502>
- [34] P. Antal, H. Verrelst, D. Timmerman, Y. Moreau, S. V. Huffel, B. D. Moor, and I. Vergote, "Bayesian networks in ovarian cancer diagnosis: potentials and limitations," in *Proceedings 13th IEEE Symposium on Computer-Based Medical Systems. CBMS 2000*, 6 2000, pp. 103–108.
- [35] W. H. Wu, M. A. Batalin, W. J. Kaiser, M. Sarrafzadeh, and A. A. T. Bui, "A novel method and testbed for sensor management and patient diagnosis," in *2007 Joint Workshop*

on High Confidence Medical Devices, Software, and Systems and Medical Device Plug-and-Play Interoperability (HCMDSS-MDPnP 2007), 6 2007, pp. 76–87.